

# Markdown\_Week12\_Analyzing\_data

Aymeric Collart

## 1. Prepare the environment

### 1.1 Load the libraries

```
library(quanteda)
```

```
## Package version: 4.3.1  
## Unicode version: 14.0  
## ICU version: 71.1
```

```
## Parallel computing: disabled
```

```
## See https://quanteda.io for tutorials and examples.
```

```
library(quanteda.textstats)  
library(jiebaR)
```

```
## Loading required package: jiebaRD
```

```
library(tidytext)  
library(dplyr)
```

```
##  
## Attaching package: 'dplyr'
```

```
## The following objects are masked from 'package:stats':  
##  
##   filter, lag
```

```
## The following objects are masked from 'package:base':  
##  
##   intersect, setdiff, setequal, union
```

```
library(jiebaR)  
library(openxlsx)
```

```
#Sys.setlocale(category = "LC_ALL", locale = "cht")
```

## 1.2 Load the originally scraped data

```
load(file = "ArticleETToday_CorpusCourse_CLEAN.Rdata")
```

## 2. Key Word In Context (KWIC)

### 2.1 Set the segmenter (for Chinese)

```
seg_word <- worker(bylines = T,  
                   symbol=T)  
  
seg_POS <- worker(type = "tag",  
                  symbol = F)
```

### 2.2 Prepare the dataset for the analyses

```
Article_total2$docname <- paste0("text",  
                                 1:nrow(Article_total2))  
  
Article_tokens <- Article_total2$body %>%  
  segment(jiebar = seg_word) %>%  
  as.tokens
```

### 2.3 Perform the KWIC segmentation

#### 2.3.1 Corpus with POS information on the following word

```
kwic_data <- kwic(Article_tokens,  
                  pattern = " 有",  
                  window = 1)  
  
RightPost_Annot <- segment(kwic_data$post, seg_POS)  
  
## Convert to dataframe  
RightPost_Annot <- do.call(rbind,  
                           lapply(RightPost_Annot,  
                                  as.data.frame))  
  
RightPost_Annot <- cbind(POS = rownames(RightPost_Annot),  
                        RightPost_Annot)  
  
rownames(RightPost_Annot) <- 1:nrow(RightPost_Annot)  
  
names(RightPost_Annot)[2] <- "RightPost"
```

```

RightPost_Annot$POS <- gsub("[0-9]+", "", RightPost_Annot$POS)

RightPost_Annot <- RightPost_Annot[!duplicated(RightPost_Annot), ]

names(RightPost_Annot)[2] <- "post"

kwic_data <- right_join(kwic_data,
                        RightPost_Annot,
                        by = "post")

```

### 2.3.2 Corpus with longer sentences

```

kwic_data2 <- kwic(Article_tokens,
                  pattern = "有",
                  window = 15)

```

### 2.3.3 Combine the two datasets together

```

### Prepare the dataset with longer sentences
kwic_data2 <- as.data.frame(kwic_data2)

kwic_data2$Index <- paste0(kwic_data2$docname,
                           kwic_data2$from)

kwic_data2_selected <- kwic_data2 %>%
  select(docname, pre, post, Index)

### Prepare the dataset with the POS information
kwic_data <- as.data.frame(kwic_data)

names(kwic_data)[6] <- "post_1word"

kwic_data_selected <- kwic_data %>%
  select(docname, from, to, post_1word, keyword, POS)

kwic_data_selected$Index <- paste0(kwic_data_selected$docname,
                                   kwic_data_selected$from)

### Join the two datasets
kwic_data <- right_join(kwic_data_selected,
                        kwic_data2_selected,
                        by = "Index")

```

```

## Warning in right_join(kwic_data_selected, kwic_data2_selected, by = "Index"): Detected an unexpected
## i Row 49 of `x` matches multiple rows in `y`.
## i Row 51 of `y` matches multiple rows in `x`.
## i If a many-to-many relationship is expected, set `relationship =
##   "many-to-many"` to silence this warning.

```

```
### Change the location of the columns for convenience
kwic_data <- kwic_data %>%
  relocate(keyword, .after = pre)
kwic_data <- kwic_data %>%
  relocate(post_1word, .after = keyword)
```

### 2.3.4 (Optional) Select the sentences we are interested in

For this example, we are interested in the sentences where the character 有 ‘you’ (to have) is followed immediately by a verb (to simplify in this example, when POS = ‘v’)

```
kwic_you_verb <- kwic_data[kwic_data$POS == "v", ]

table_YouVerb <- table(kwic_you_verb$post_1word)
table_YouVerb <- as.data.frame(table_YouVerb)

names(table_YouVerb)[1] <- "Verb"
table_YouVerb <- table_YouVerb %>%
  arrange(desc(Freq))
table_YouVerb_Top10 <- head(table_YouVerb, 10)
table_YouVerb_Top10
```

```
##      Verb Freq
## 1 可能 899
## 2 逃亡 372
## 3 相關 304
## 4 需要 254
## 5 看到 192
## 6 超過 186
## 7 ㄟ押 183
## 8 疑慮 161
## 9 發生 143
## 10 幫助 132
```

*## As you can see, even if the POS tagging is useful, it's not completely reliable.*

## 2.4 Save the data

### 2.4.1 Save as an Excel file

```
write.xlsx(kwic_you_verb, "ArticleETToday_KWIC_You.xlsx")
```

### 2.4.2 Save as an RData file

```
save(kwic_you_verb, file = "ArticleETToday_KWIC_You.Rdata")
```

### 3. Frequency tables

#### 3.1 Create the overall frequency table

##### 3.1.1 Creation of the first table

```
## We need to tranform the tokenized data into a 'dfm' dataset
Article_tokens_frequency <- dfm(Article_tokens)
Article_tokens_frequency <- textstat_frequency(Article_tokens_frequency)

table_AllWordsFreq_Top100 <- head(Article_tokens_frequency, 100)
table_AllWordsFreq_Top100
```

##	feature	frequency	rank	docfreq	group
## 1	,	1644510	1	237409	all
## 2	的	370860	2	161174	all
## 3	。	337831	3	230147	all
## 4	、	232573	4	115421	all
## 5	「	153920	5	92773	all
## 6	」	153854	6	92734	all
## 7	在	138401	7	99935	all
## 8	是	98718	8	70585	all
## 9	也	85523	9	67916	all
## 10	有	77572	10	60208	all
## 11	日	73899	11	61032	all
## 12	後	66276	12	54287	all
## 13	與	59328	13	47584	all
## 14	區	56468	14	46797	all
## 15	他	53478	15	37078	all
## 16	表示	49438	16	47103	all
## 17	都	48572	17	38815	all
## 18	人	48010	18	37467	all
## 19	但	46043	19	41562	all
## 20	時	45949	20	38995	all
## 21	年	45537	21	32132	all
## 22	月	44994	22	33768	all
## 23	不	44304	23	36119	all
## 24	2	44074	24	34530	all
## 25	被	43016	25	35411	all
## 26	等	42082	26	35047	all
## 27	及	41314	27	32635	all
## 28	要	40613	28	31869	all
## 29	了	40276	29	32505	all
## 30		38709	30	11503	all
## 31	就	37864	31	31992	all
## 32	會	37195	32	30211	all
## 33	(	36863	33	30325	all
## 34	)	36812	34	30289	all
## 35	1	36679	35	28854	all
## 36	陳	35683	36	23660	all
## 37	3	34953	37	28842	all
## 38	?	34326	38	23458	all

## 39	警 方	34271	39	26258	all
## 40	男	32284	40	20601	all
## 41	到	31541	41	27762	all
## 42	㊦	31060	42	27013	all
## 43	台 灣	30730	43	20924	all
## 44	中	30631	44	27383	all
## 45	她	29945	45	18663	all
## 46	㊦	29901	46	27640	all
## 47	民 進 黨	29638	47	20901	all
## 48	㊦ 有	28581	48	23855	all
## 49	民 ㊦	28319	49	22482	all
## 50	對	28167	50	24378	all
## 51	讓	27701	51	24097	all
## 52	；	27099	52	23338	all
## 53	歲	26212	53	18841	all
## 54	發 生	25313	54	22034	all
## 55	國 民 黨	24924	55	17728	all
## 56	而	24849	56	23074	all
## 57	於	24782	57	21452	all
## 58	上	24503	58	22165	all
## 59	我	24467	59	14684	all
## 60	發 現	23505	60	20672	all
## 61	以	23215	61	21098	all
## 62	指 出	22959	62	22662	all
## 63	4	22918	63	19929	all
## 64	之	22418	64	14479	all
## 65	自 己	22270	65	18894	all
## 66	立 委	22238	66	16598	all
## 67	柯 文	21775	67	13623	all
## 68	5	21646	68	19044	all
## 69	跟	21143	69	17572	all
## 70	和	20834	70	17259	all
## 71	將	20727	71	19307	all
## 72	已	20682	72	18945	all
## 73	男 子	20610	73	15377	all
## 74	調 查	20280	74	17599	all
## 75	㊦	19825	75	13703	all
## 76	10	18612	76	16702	all
## 77	黨	18545	77	12924	all
## 78	6	18502	78	16135	all
## 79	萬 元	18322	79	13812	all
## 80	總 統	18305	80	12866	all
## 81	才	18030	81	16679	all
## 82	8	17787	82	15900	all
## 83	相 關	17758	83	15865	all
## 84	㊦	17579	84	16499	all
## 85	或	17538	85	13994	all
## 86	因	17246	86	16127	all
## 87	更	17227	87	15212	all
## 88	前	17182	88	15253	all
## 89	進 行	17167	89	15401	all
## 90	向	16664	90	15359	all
## 91	可 以	16515	91	14273	all
## 92	認 ㊦	15942	92	14762	all

## 93	仍	15882	93	14872	all
## 94	現場	15647	94	13401	all
## 95	就是	15632	95	13924	all
## 96	政府	15602	96	12846	all
## 97	台	15314	97	12904	all
## 98	哲	15242	98	10843	all
## 99	7	14980	99	13552	all
## 100	!	14928	100	12213	all

### 3.1.2 Clean it up a little bit

```
## Example with punctuation marks
table_FreqWord <- Article_tokens_frequency[-grep(",", Article_tokens_frequency$feature),]
table_FreqWord <- table_FreqWord[-grep("。", table_FreqWord$feature),]
table_FreqWord <- table_FreqWord[-grep("、", table_FreqWord$feature),]
table_FreqWord <- table_FreqWord[-grep("「", table_FreqWord$feature),]
table_FreqWord <- table_FreqWord[-grep("」", table_FreqWord$feature),]
table_FreqWord <- table_FreqWord[-grep("(", table_FreqWord$feature),]
table_FreqWord <- table_FreqWord[-grep(")", table_FreqWord$feature),]
table_FreqWord <- table_FreqWord[-grep("?", table_FreqWord$feature),]
table_FreqWord <- table_FreqWord[-grep(";", table_FreqWord$feature),]
table_FreqWord <- table_FreqWord[-grep("!", table_FreqWord$feature),]
table_FreqWord <- table_FreqWord[-grep("《", table_FreqWord$feature),]
table_FreqWord <- table_FreqWord[-grep("》", table_FreqWord$feature),]

## Example with numbers
table_FreqWord <- table_FreqWord[-grep("[[:digit:]]", table_FreqWord$feature),]
```

### 3.1.3 Final table, addition of the percentage

```
table_FreqWord_Top100 <- head(table_FreqWord, 100)
table_FreqWord_Top100
```

##	feature	frequency	rank	docfreq	group
## 2	的	370860	2	161174	all
## 7	在	138401	7	99935	all
## 8	是	98718	8	70585	all
## 9	也	85523	9	67916	all
## 10	有	77572	10	60208	all
## 11	日	73899	11	61032	all
## 12	後	66276	12	54287	all
## 13	與	59328	13	47584	all
## 14	ㄟ	56468	14	46797	all
## 15	他	53478	15	37078	all
## 16	表示	49438	16	47103	all
## 17	都	48572	17	38815	all
## 18	人	48010	18	37467	all
## 19	但	46043	19	41562	all
## 20	時	45949	20	38995	all
## 21	年	45537	21	32132	all

## 22	月	44994	22	33768	all
## 23	不	44304	23	36119	all
## 25	被	43016	25	35411	all
## 26	等	42082	26	35047	all
## 27	及	41314	27	32635	all
## 28	要	40613	28	31869	all
## 29	了	40276	29	32505	all
## 30		38709	30	11503	all
## 31	就	37864	31	31992	all
## 32	會	37195	32	30211	all
## 36	陳	35683	36	23660	all
## 39	警方	34271	39	26258	all
## 40	男	32284	40	20601	all
## 41	到	31541	41	27762	all
## 42	㊦	31060	42	27013	all
## 43	台灣	30730	43	20924	all
## 44	中	30631	44	27383	all
## 45	她	29945	45	18663	all
## 46	㊦	29901	46	27640	all
## 47	民進黨	29638	47	20901	all
## 48	㊦有	28581	48	23855	all
## 49	民㊦	28319	49	22482	all
## 50	對	28167	50	24378	all
## 51	讓	27701	51	24097	all
## 53	歲	26212	53	18841	all
## 54	發生	25313	54	22034	all
## 55	國民黨	24924	55	17728	all
## 56	而	24849	56	23074	all
## 57	於	24782	57	21452	all
## 58	上	24503	58	22165	all
## 59	我	24467	59	14684	all
## 60	發現	23505	60	20672	all
## 61	以	23215	61	21098	all
## 62	指出	22959	62	22662	all
## 64	之	22418	64	14479	all
## 65	自己	22270	65	18894	all
## 66	立委	22238	66	16598	all
## 67	柯文	21775	67	13623	all
## 69	跟	21143	69	17572	all
## 70	和	20834	70	17259	all
## 71	將	20727	71	19307	all
## 72	已	20682	72	18945	all
## 73	男子	20610	73	15377	all
## 74	調查	20280	74	17599	all
## 75	㊦	19825	75	13703	all
## 77	黨	18545	77	12924	all
## 79	萬元	18322	79	13812	all
## 80	總統	18305	80	12866	all
## 81	才	18030	81	16679	all
## 83	相關	17758	83	15865	all
## 84	㊦	17579	84	16499	all
## 85	或	17538	85	13994	all
## 86	因	17246	86	16127	all
## 87	更	17227	87	15212	all



## 88	前	17182	88	15253	all
## 89	進行	17167	89	15401	all
## 90	向	16664	90	15359	all
## 91	可以	16515	91	14273	all
## 92	認	15942	92	14762	all
## 93	仍	15882	93	14872	all
## 94	現場	15647	94	13401	all
## 95	就是	15632	95	13924	all
## 96	政府	15602	96	12846	all
## 97	台	15314	97	12904	all
## 98	哲	15242	98	10843	all
## 101	再	14704	101	13627	all
## 102	目前	14474	102	13512	all
## 103	立法院	14440	103	11229	all
## 106	從	14154	106	13201	all
## 107	名	14116	107	11868	all
## 108	且	14051	108	13272	all
## 109	又	13972	109	12665	all
## 110	由	13840	110	12568	all
## 111	人員	13525	111	11281	all
## 112	因	13423	112	12568	all
## 113	已經	13395	113	12304	all
## 115	希望	13141	115	11708	all
## 116	依	13123	116	12448	all
## 117	駕駛	13123	116	9729	all
## 118	這	13041	118	11926	all
## 119	遭	12767	119	11703	all
## 120	很	12570	120	10877	all
## 121	因此	12465	121	11939	all
## 122	大	12294	122	10741	all

```
table_FreqWord_Top100$percentage <-
  ↪ round(table_FreqWord_Top100$frequency/sum(table_FreqWord$frequency)*100, 4)
table_FreqWord_Top100
```

##	feature	frequency	rank	docfreq	group	percentage
## 2	的	370860	2	161174	all	2.7226
## 7	在	138401	7	99935	all	1.0160
## 8	是	98718	8	70585	all	0.7247
## 9	也	85523	9	67916	all	0.6279
## 10	有	77572	10	60208	all	0.5695
## 11	日	73899	11	61032	all	0.5425
## 12	後	66276	12	54287	all	0.4866
## 13	與	59328	13	47584	all	0.4355
## 14		56468	14	46797	all	0.4145
## 15	他	53478	15	37078	all	0.3926
## 16	表示	49438	16	47103	all	0.3629
## 17	都	48572	17	38815	all	0.3566
## 18	人	48010	18	37467	all	0.3525
## 19	但	46043	19	41562	all	0.3380
## 20	時	45949	20	38995	all	0.3373
## 21	年	45537	21	32132	all	0.3343
## 22	月	44994	22	33768	all	0.3303

## 23	不	44304	23	36119	all	0.3252
## 25	被	43016	25	35411	all	0.3158
## 26	等	42082	26	35047	all	0.3089
## 27	及	41314	27	32635	all	0.3033
## 28	要	40613	28	31869	all	0.2982
## 29	了	40276	29	32505	all	0.2957
## 30		38709	30	11503	all	0.2842
## 31	就	37864	31	31992	all	0.2780
## 32	會	37195	32	30211	all	0.2731
## 36	陳	35683	36	23660	all	0.2620
## 39	警	34271	39	26258	all	0.2516
## 40	男	32284	40	20601	all	0.2370
## 41	到	31541	41	27762	all	0.2316
## 42	【F】	31060	42	27013	all	0.2280
## 43	台	30730	43	20924	all	0.2256
## 44	中	30631	44	27383	all	0.2249
## 45	她	29945	45	18663	all	0.2198
## 46	【F】	29901	46	27640	all	0.2195
## 47	民進黨	29638	47	20901	all	0.2176
## 48	【F】有	28581	48	23855	all	0.2098
## 49	民【F】	28319	49	22482	all	0.2079
## 50	對	28167	50	24378	all	0.2068
## 51	讓	27701	51	24097	all	0.2034
## 53	歲	26212	53	18841	all	0.1924
## 54	發	25313	54	22034	all	0.1858
## 55	國	24924	55	17728	all	0.1830
## 56	民	24849	56	23074	all	0.1824
## 57	而	24782	57	21452	all	0.1819
## 58	於	24503	58	22165	all	0.1799
## 59	上	24467	59	14684	all	0.1796
## 60	我	23505	60	20672	all	0.1726
## 61	發	23215	61	21098	all	0.1704
## 62	現	22959	62	22662	all	0.1685
## 64	以	22418	64	14479	all	0.1646
## 65	指	22270	65	18894	all	0.1635
## 66	出	22238	66	16598	all	0.1633
## 67	之	21775	67	13623	all	0.1599
## 69	自	21143	69	17572	all	0.1552
## 70	己	20834	70	17259	all	0.1529
## 71	立	20727	71	19307	all	0.1522
## 72	委	20682	72	18945	all	0.1518
## 73	柯	20610	73	15377	all	0.1513
## 74	文	20280	74	17599	all	0.1489
## 75	跟	19825	75	13703	all	0.1455
## 77	和	18545	77	12924	all	0.1361
## 79	將	18322	79	13812	all	0.1345
## 80	已	18305	80	12866	all	0.1344
## 81	男	18030	81	16679	all	0.1324
## 83	子	17758	83	15865	all	0.1304
## 84	調	17579	84	16499	all	0.1291
## 85	查	17538	85	13994	all	0.1288
## 86	【F】	17246	86	16127	all	0.1266
## 87	黨	17227	87	15212	all	0.1265
## 88	萬	17182	88	15253	all	0.1261
## 89	元					
## 90	總					
## 91	統					
## 92	才					
## 93	相					
## 94	關					
## 95	【F】					
## 96	或					
## 97	因					
## 98	更					
## 99	前					

## 89	進 行	17167	89	15401	all	0.1260
## 90	向	16664	90	15359	all	0.1223
## 91	可 以	16515	91	14273	all	0.1212
## 92	認 ㄟ	15942	92	14762	all	0.1170
## 93	仍	15882	93	14872	all	0.1166
## 94	現 場	15647	94	13401	all	0.1149
## 95	就 是	15632	95	13924	all	0.1148
## 96	政 府	15602	96	12846	all	0.1145
## 97	台	15314	97	12904	all	0.1124
## 98	哲	15242	98	10843	all	0.1119
## 101	再	14704	101	13627	all	0.1079
## 102	目 前	14474	102	13512	all	0.1063
## 103	立 法 院	14440	103	11229	all	0.1060
## 106	從	14154	106	13201	all	0.1039
## 107	名	14116	107	11868	all	0.1036
## 108	且	14051	108	13272	all	0.1032
## 109	又	13972	109	12665	all	0.1026
## 110	由	13840	110	12568	all	0.1016
## 111	人 員	13525	111	11281	all	0.0993
## 112	因 ㄟ	13423	112	12568	all	0.0985
## 113	已 經	13395	113	12304	all	0.0983
## 115	希 望	13141	115	11708	all	0.0965
## 116	依	13123	116	12448	all	0.0963
## 117	駕 駛	13123	116	9729	all	0.0963
## 118	這	13041	118	11926	all	0.0957
## 119	遭	12767	119	11703	all	0.0937
## 120	很	12570	120	10877	all	0.0923
## 121	因 此	12465	121	11939	all	0.0915
## 122	大	12294	122	10741	all	0.0903

## 3.2 Select only the 100 most frequent nouns

There are several ways to do it. We could use the raw data one more time. But since this is quite a large dataset, it will take a lot of time to process. An alternative way is to compute the 500 most frequent words, and hopefully there will be 100 nouns. [After trying 300 words, it was not enough. Tests with more words done after]

### 3.2.1 Set the segmenter

```
seg_POS_ByLines <- worker(type = "tag",
                           bylines = FALSE,
                           symbol = F)
```

### 3.2.2 Proceed to the segmentation and annotate

```
table_FreqWord_Top500 <- head(table_FreqWord, 500)

Top500_WordFreqPOS <- segment(table_FreqWord_Top500$feature,
                              seg_POS_ByLines)
```

```
## Convert to dataframe
Top500_WordFreqPOS_Annotated <- do.call(rbind,
                                         lapply(Top500_WordFreqPOS,
                                                as.data.frame))

Top500_WordFreqPOS_Annotated <- cbind(POS = rownames(Top500_WordFreqPOS_Annotated),
                                     Top500_WordFreqPOS_Annotated)

rownames(Top500_WordFreqPOS_Annotated) <- 1:nrow(Top500_WordFreqPOS_Annotated)

names(Top500_WordFreqPOS_Annotated)[2] <- "Word"

Top500_WordFreqPOS_Annotated$POS <- gsub("[0-9]+", "", Top500_WordFreqPOS_Annotated$POS)
```

### 3.2.3 Extract the nouns (POS = n, to make it simple) and annotate

```
TopFreqNoun <- Top500_WordFreqPOS_Annotated[Top500_WordFreqPOS_Annotated$POS == "n", ]
TopFreqNoun$Index <- "TopNouns"

names(table_FreqWord)[1] <- "Word"
TopFreqNoun <- right_join(TopFreqNoun,
                          table_FreqWord,
                          by = "Word")

TopFreqNoun$Percentage <- round(TopFreqNoun$frequency/sum(TopFreqNoun$frequency)*100, 4)

TopFreqNoun <- TopFreqNoun[+grep("TopNouns", TopFreqNoun$Index),]

table_FreqNoun_Top100 <- head(TopFreqNoun, 100)
table_FreqNoun_Top100 <- table_FreqNoun_Top100 %>%
  arrange(desc(frequency))
table_FreqNoun_Top100
```

##	POS	Word	Index	frequency	rank	docfreq	group	Percentage
## 1	n	人	TopNouns	48010	18	37467	all	0.3525
## 2	n	警方	TopNouns	34271	39	26258	all	0.2516
## 3	n	男	TopNouns	32284	40	20601	all	0.2370
## 4	n	男子	TopNouns	20610	73	15377	all	0.1513
## 5	n	黨	TopNouns	18545	77	12924	all	0.1361
## 6	n	總統	TopNouns	18305	80	12866	all	0.1344
## 7	n	現場	TopNouns	15647	94	13401	all	0.1149
## 8	n	政府	TopNouns	15602	96	12846	all	0.1145
## 9	n	哲	TopNouns	15242	98	10843	all	0.1119
## 10	n	人員	TopNouns	13525	111	11281	all	0.0993
## 11	n	分局	TopNouns	12237	125	10362	all	0.0898
## 12	n	公司	TopNouns	11992	131	8170	all	0.0880
## 13	n	國會	TopNouns	11801	134	8217	all	0.0866
## 14	n	大家	TopNouns	11582	139	9814	all	0.0850
## 15	n	國家	TopNouns	11264	143	9123	all	0.0827
## 16	n	市長	TopNouns	11252	145	8707	all	0.0826

## 17	n	問題	TopNouns	11013	152	9618	all	0.0808
## 18	n	法官	TopNouns	10815	155	9100	all	0.0794
## 19	n	政治	TopNouns	10357	167	8522	all	0.0760
## 20	n	媒體	TopNouns	10217	169	8956	all	0.0750
## 21	n	☐	TopNouns	10181	173	9454	all	0.0747
## 22	n	原因	TopNouns	9894	183	9026	all	0.0726
## 23	n	社會	TopNouns	9695	190	8305	all	0.0712
## 24	n	案	TopNouns	9390	196	7994	all	0.0689
## 25	n	時間	TopNouns	9327	201	8440	all	0.0685
## 26	n	處	TopNouns	9207	205	8013	all	0.0676
## 27	n	主席	TopNouns	9099	208	7533	all	0.0668
## 28	n	檢方	TopNouns	9041	210	7703	all	0.0664
## 29	n	部分	TopNouns	8834	214	7798	all	0.0649
## 30	n	員警	TopNouns	8766	216	6217	all	0.0644
## 31	n	無法	TopNouns	8763	217	8164	all	0.0643
## 32	n	結果	TopNouns	8383	230	7803	all	0.0615
## 33	n	黨團	TopNouns	8342	231	6193	all	0.0612
## 34	n	地方	TopNouns	8325	232	6750	all	0.0611
## 35	n	女子	TopNouns	8263	235	6157	all	0.0607
## 36	n	法院	TopNouns	8155	239	7162	all	0.0599
## 37	n	規定	TopNouns	7999	243	7044	all	0.0587
## 38	n	院長	TopNouns	7962	244	5828	all	0.0585
## 39	n	委員會	TopNouns	7875	246	5909	all	0.0578
## 40	n	過程	TopNouns	7861	247	7463	all	0.0577
## 41	n	民主	TopNouns	7694	251	5686	all	0.0565
## 42	n	醫院	TopNouns	7664	254	6453	all	0.0563
## 43	n	檢察官	TopNouns	7551	257	6228	all	0.0554
## 44	n	全案	TopNouns	7532	260	7325	all	0.0553
## 45	n	案件	TopNouns	7460	261	6592	all	0.0548
## 46	n	事件	TopNouns	7376	264	6612	all	0.0541
## 47	n	機車	TopNouns	7326	267	5435	all	0.0538
## 48	n	人民	TopNouns	7206	272	5976	all	0.0529
## 49	n	區	TopNouns	7113	277	6579	all	0.0522
## 50	n	方式	TopNouns	6919	284	6453	all	0.0508
## 51	n	車輛	TopNouns	6838	290	5600	all	0.0502
## 52	n	雙方	TopNouns	6810	292	6118	all	0.0500
## 53	n	議員	TopNouns	6735	295	5408	all	0.0494
## 54	n	著	TopNouns	6652	298	6260	all	0.0488
## 55	n	被告	TopNouns	6502	303	3997	all	0.0477
## 56	n	市府	TopNouns	6493	304	4954	all	0.0477
## 57	n	狀☐	TopNouns	6437	310	6044	all	0.0473
## 58	n	行政院	TopNouns	6426	312	5124	all	0.0472
## 59	n	毒品	TopNouns	6292	315	3659	all	0.0462
## 60	n	報案	TopNouns	6162	323	5758	all	0.0452
## 61	n	事故	TopNouns	6158	324	5149	all	0.0452
## 62	n	☐容	TopNouns	6007	331	5475	all	0.0441
## 63	n	家屬	TopNouns	5996	333	4819	all	0.0440
## 64	n	條例	TopNouns	5985	335	5286	all	0.0439
## 65	n	影片	TopNouns	5982	336	4701	all	0.0439
## 66	n	報告	TopNouns	5832	344	4770	all	0.0428
## 67	n	國際	TopNouns	5798	349	4597	all	0.0426
## 68	n	單位	TopNouns	5681	358	5186	all	0.0417
## 69	n	集團	TopNouns	5639	363	4536	all	0.0414
## 70	n	對方	TopNouns	5500	369	4721	all	0.0404

## 71	n	學生	TopNouns	5427	373	3518	all	0.0398
## 72	n	通報	TopNouns	5425	374	4853	all	0.0398
## 73	n	路	TopNouns	5415	375	4800	all	0.0398
## 74	n	憲法	TopNouns	5346	380	3535	all	0.0392
## 75	n	法案	TopNouns	5275	385	4245	all	0.0387
## 76	n	手機	TopNouns	5274	386	4288	all	0.0387
## 77	n	委員	TopNouns	5254	389	4054	all	0.0386
## 78	n	珊	TopNouns	5207	392	2150	all	0.0382
## 79	n	事情	TopNouns	5188	395	4685	all	0.0381
## 80	n	律師	TopNouns	5176	397	3722	all	0.0380
## 81	n	監視器	TopNouns	5134	399	4708	all	0.0377
## 82	n	派出所	TopNouns	5116	402	4470	all	0.0376
## 83	n	程序	TopNouns	5066	404	4404	all	0.0372
## 84	n	司法	TopNouns	5046	406	4148	all	0.0370
## 85	n	政策	TopNouns	4943	412	4173	all	0.0363
## 86	n	畫面	TopNouns	4930	413	4469	all	0.0362
## 87	n	警	TopNouns	4926	416	4679	all	0.0362
## 88	n	關	TopNouns	4924	417	4456	all	0.0361
## 89	n	車禍	TopNouns	4904	421	4310	all	0.0360
## 90	n	資料	TopNouns	4873	424	4129	all	0.0358
## 91	n	團	TopNouns	4859	429	4133	all	0.0357
## 92	n	中央	TopNouns	4857	431	3952	all	0.0357
## 93	n	被害人	TopNouns	4746	442	3235	all	0.0348
## 94	n	網友	TopNouns	4671	449	3889	all	0.0343
## 95	n	中心	TopNouns	4603	454	3899	all	0.0338
## 96	n	報警	TopNouns	4579	459	4454	all	0.0336
## 97	n	大陸	TopNouns	4559	461	3403	all	0.0335
## 98	n	罪嫌	TopNouns	4505	466	4307	all	0.0331
## 99	n	肇事	TopNouns	4501	467	3896	all	0.0330
## 100	n	依法	TopNouns	4488	469	4267	all	0.0329

## Again, you can see that some entries are a little bit weird. There are several ways to  
 ↪ handle them, but we will not cover them in class

### 3.3 Save the data

#### 3.3.1 Save as an Excel file

```
write.xlsx(table_FreqNoun_Top100, "ArticleETToday_Top100nouns.xlsx")
```

#### 3.3.2 Save as an RData file

```
save(table_FreqNoun_Top100, file = "ArticleETToday_Top100nouns.Rdata")
```