

Markdown_Week12_Analyzing_data_QuantedaOnly

Aymeric Collart

1. Prepare the environment

1.1 Load the libraries

```
library(quanteda)
```

```
## Package version: 4.3.1  
## Unicode version: 14.0  
## ICU version: 71.1
```

```
## Parallel computing: disabled
```

```
## See https://quanteda.io for tutorials and examples.
```

```
library(quanteda.textstats)  
library(tidytext)  
library(dplyr)
```

```
##  
## Attaching package: 'dplyr'
```

```
## The following objects are masked from 'package:stats':  
##  
##   filter, lag
```

```
## The following objects are masked from 'package:base':  
##  
##   intersect, setdiff, setequal, union
```

```
library(stringr)  
library(openxlsx)
```

```
#Sys.setlocale(category = "LC_ALL", locale = "cht")
```

1.2 Load the originally scraped data

```
load(file = "ArticleETToday_CorpusCourse_CLEAN.Rdata")
```

2. Key Word In Context (KWIC)

2.1 Prepare the dataset for the analyses

```
Article_total2$docname <- paste0("text",  
                                1:nrow(Article_total2))  
  
Article_tokens <- tokens(Article_total2$body)
```

2.2 Perform the KWIC segmentation

2.2.1 KWIC segmentation

```
kwic_data <- kwic(Article_tokens,  
                 pattern = "有",  
                 window = 30)
```

2.2.2 Annotate the KWIC dataset

```
kwic_data <- as.data.frame(kwic_data)  
  
kwic_data <- right_join(kwic_data,  
                      Article_total2,  
                      by = "docname")  
  
kwic_data <- na.omit(kwic_data)
```

2.2.3 (Optional) Clean the context to keep only the phrase where the keyword is found

```
## Keep original information just in case  
kwic_data$pre_original <- kwic_data$pre  
kwic_data$post_original <- kwic_data$post  
  
## Post context  
symbol1 <- "\\。 "  
kwic_data$post <- sub(paste0("(", symbol1, ").*"), "\\1", kwic_data$post)  
  
symbol2 <- "\\, "  
kwic_data$post <- sub(paste0("(", symbol2, ").*"), "\\1", kwic_data$post)  
  
symbol3 <- "\\? "
```

```

kwic_data$post <- sub(paste0("(", symbol3, ").*"), "\\1", kwic_data$post)

symbol4 <- "\\! "
kwic_data$post <- sub(paste0("(", symbol4, ").*"), "\\1", kwic_data$post)

## Pre context
kwic_data$pre <- sub(".*. ([^*.]*)$", ". \\1", kwic_data$pre)
kwic_data$pre <- sub(".*. ([^*.]*)$", ", \\1", kwic_data$pre)
kwic_data$pre <- sub(".*? ([^*?]*)$", "? \\1", kwic_data$pre)
kwic_data$pre <- sub(".*! ([^*!]*)$", "! \\1", kwic_data$pre)

## Have a look at the data (I delete some columns so that it is easier to display on the
  ↪ website)
kwic_data_for_website <- kwic_data
kwic_data_for_website$original_article <- NULL
kwic_data_for_website$body <- NULL
kwic_data_for_website$pre_original <- NULL
kwic_data_for_website$post_original <- NULL
knitr::kable(head(kwic_data_for_website))

```

docno	fronto	pre	keyword	post	pattern	time	class	title	url	yearmonthday
text119	19	，竟然	有	玩家突發奇想將兩款🎮戲尬在一起，	有	2024年01月01日10:57	政治	神人把《我的世界》改成《血源詛咒》 還原度超高玩家狂敲碗：快點出	https://www.ettoday.net/news/20231231/2652951.htm	202401 01
text655	55	，但已經	有	不少玩家表示相當期待，	有	2024年01月01日10:57	政治	神人把《我的世界》改成《血源詛咒》 還原度超高玩家狂敲碗：快點出	https://www.ettoday.net/news/20231231/2652951.htm	202401 01
text128	18	，常見補品	有	燒酒🍷、🍷母鴨、羊肉爐、藥🍷排骨等，	有	2024年01月01日09:07	社會	跨年冬令進補爐火需留意 安裝住宅用火🍷警報器避免悲劇	https://www.ettoday.net/news/20231231/2652951.htm	202401 01
text147	57	，選擇	有	熄火安全裝置及🍷度感知功能爐具，	有	2024年01月01日09:07	社會	跨年冬令進補爐火需留意 安裝住宅用火🍷警報器避免悲劇	https://www.ettoday.net/news/20231231/2652951.htm	202401 01
text130	30	，發現29歲林姓男子涉	有	重嫌，	有	2024年01月01日10:29	社會	半工半讀買的機車被偷！23歲女人生第一輛 警埋伏 10hrs 抓賊	https://www.ettoday.net/news/20231231/2652951.htm	202401 01

docname	fronto	pre	keyword	post	pattern	time	class	title	url	yearmonthday
text146	46	, 網友 始知台 灣改車 界	有	這號人物存在。	有	2024 年 01 月 01 日 13:00	社會	揭密廖老大打龜 號進化史! 他 台積電工程師 兩 岸改裝達人之 曝	https: //www. ettoday.net/ news/ 20231231/ 2652951.htm	202401 01

2.2.4 Combined analysis: Frequency table of the first word following *you* ‘to have’

```
## Extract the first word
kwic_data$post_first_word <- word(kwic_data$post, 1)

## We need to tranform the tokenized data into a 'dfm' dataset
kwic_data_freq <- dfm(
  tokens(kwic_data$post_first_word,
    remove_punct = TRUE)
)

kwic_data_freq <- textstat_frequency(kwic_data_freq)

## Clean a little bit
kwic_data_freq <- kwic_data_freq[-grep("[[:digit:]]", kwic_data_freq$feature),]

## Recreate the rank
kwic_data_freq$rank <- 1:length(kwic_data_freq$rank)

knitr::kable(head(kwic_data_freq, 100))
```

	feature	frequency	rank	docfreq	group
1	民	1291	1	1291	all
3	多	694	2	694	all
4	網友	656	3	656	all
5	很多	608	4	608	all
6		600	5	600	all
7	問題	588	6	588	all
8	什	580	7	580	all
10	媒體	550	8	550	all
11	的	533	9	533	all
12	一名	503	10	503	all
14	任何	476	11	476	all
15	逃亡	445	12	445	all
16	可能	437	13	437	all
17	許多	399	14	399	all
18	機會	395	15	395	all
19	一個	338	16	338	all
21	信心	298	17	298	all
22	其他	298	18	298	all
23	在	271	19	271	all
24	更多	264	20	264	all

	feature	frequency	rank	docfreq	group
25	一些	262	21	262	all
26	勾	256	22	256	all
27	相當	249	23	249	all
28	不少	234	24	234	all
29	需要	228	25	228	all
30	重	223	26	223	all
31	這樣	222	27	222	all
32	跟	222	28	222	all
33	必要	220	29	220	all
35	時	207	30	207	all
36	不同	200	31	200	all
37	毒品	198	32	198	all
38	能力	196	33	196	all
39	多少	194	34	194	all
40	違	191	35	191	all
43	這	181	36	181	all
44	非常	181	37	181	all
45	部分	177	38	177	all
46	押	176	39	176	all
48	相關	172	40	172	all
49	一定	169	41	169	all
50	明顯	162	42	162	all
51	共識	156	43	156	all
53	串	153	44	153	all
54	超過	152	45	152	all
55	被	151	46	151	all
56	責任	149	47	149	all
57	重大	147	48	147	all
58	很大	147	49	147	all
59	違反	140	50	140	all
60	更	139	51	139	all
61	酒	135	52	135	all
62	看到	135	53	135	all
63	疑慮	134	54	134	all
64	意願	132	55	132	all
65	意見	130	56	130	all
66	對	128	57	128	all
67	興趣	126	58	126	all
68	議	124	59	124	all
69	自己	124	60	124	all
70	發生	122	61	122	all
71	擦	120	62	120	all
72	大量	115	63	115	all
73	糾紛	111	64	111	all
74	幫助	111	65	111	all
75	一位	111	66	111	all
76	過	110	67	110	all
77	向	108	68	108	all
78	疏失	106	69	106	all
79	條件	106	70	106	all
80	債務	106	71	106	all
81	事實	104	72	104	all

	feature	frequency	rank	docfreq	group
82	不	103	73	103	all
83	兩個	102	74	102	all
84	高度	101	75	101	all
85	國狀	100	76	100	all
86	違法	99	77	99	all
87	據	96	78	96	all
88	多次	94	79	94	all
89	政治	93	80	93	all
90	性	93	81	93	all
92	兩	91	82	91	all
94	做	90	83	90	all
95	高達	89	84	89	all
96	男子	89	85	89	all
97	諸多	88	86	88	all
98	國常	86	87	86	all
99	瑕疵	86	88	86	all
100	大	86	89	86	all
101	過失	86	90	86	all
102	哪些	85	91	85	all
103	國	85	92	85	all
104	幾個	84	93	84	all
105	可能是	84	94	84	all
106	與	83	95	83	all
107	車輛	82	96	82	all
109	去	81	97	81	all
110	一輛	81	98	81	all
111	這種	80	99	80	all
112	藍	78	100	78	all

2.4 Save the data

2.4.1 Save as an Excel file

```
write.xlsx(kwic_data, "ArticleETToday_KWIC_You.xlsx")
```

2.4.2 Save as an RData file

```
save(kwic_data, file = "ArticleETToday_KWIC_You.Rdata")
```

3. Frequency tables

3.1 Create the overall frequency table

3.1.1 Creation of the first table

```
## We need to tranform the tokenized data into a 'dfm' dataset
Article_tokens_frequency <- dfm(
  tokens(Article_total2$body,
    remove_punct = TRUE))
Article_tokens_frequency <- textstat_frequency(Article_tokens_frequency)

table_AllWordsFreq_Top100 <- head(Article_tokens_frequency, 100)
table_AllWordsFreq_Top100
```

##	feature	frequency	rank	docfreq	group
## 1	的	357709	1	159298	all
## 2	在	116544	2	88581	all
## 3	日	84106	3	66187	all
## 4	後	71392	4	57501	all
## 5	人	69084	5	49761	all
## 6	時	67573	6	53558	all
## 7	有	65657	7	53298	all
## 8	男	63140	8	32390	all
## 9	與	61733	9	49197	all
## 10	是	59999	10	48402	all
## 11	也	59965	11	51054	all
## 12	及	49873	12	38094	all
## 13	表 示	49840	13	47384	all
## 14	年	48807	14	33965	all
## 15	但	47947	15	43097	all
## 16	他	47910	16	34208	all
## 17	將	45675	17	39070	all
## 18	等	44905	18	36914	all
## 19	被	44599	19	36588	all
## 20	到	44505	20	38318	all
## 21	2	43707	21	34342	all
## 22	月	43394	22	32669	all
## 23	姓	42361	23	28582	all
## 24	對	41664	24	35874	all
## 25	陳	41052	25	26393	all
## 26	民 ㄟ	40981	26	29991	all
## 27	要	39541	27	31461	all
## 28	ㄟ	38658	28	34703	all
## 29	台 灣	38028	29	24641	all
## 30	案	36770	30	29132	all
## 31	1	36107	31	28584	all
## 32	ㄟ	35360	32	30056	all
## 33	警 方	35205	33	26808	all
## 34	中	34824	34	30380	all
## 35	3	34319	35	28447	all
## 36	ㄟ	33596	36	29140	all

## 37	柯	33164	37	18553	all
## 38	文	32255	38	21397	all
## 39	以	32162	39	28049	all
## 40	㊦	31311	40	20937	all
## 41	上	31281	41	27774	all
## 42	不	30456	42	26271	all
## 43	民進黨	29648	43	20912	all
## 44	就	29633	44	25843	all
## 45	林	29426	45	19296	all
## 46	之	29209	46	18968	all
## 47	女	29041	47	16593	all
## 48	車	28849	48	18869	all
## 49	歲	27927	49	19862	all
## 50	讓	27838	50	24172	all
## 51	名	27598	51	22325	all
## 52	於	27440	52	23486	all
## 53	而	27073	53	25039	all
## 54	她	26964	54	17524	all
## 55	會	26866	55	22316	all
## 56	發生	26700	56	23129	all
## 57	了	25947	57	21844	all
## 58	前	25547	58	22155	all
## 59	大	25397	59	21497	all
## 60	國民黨	25126	60	17804	all
## 61	檢	24367	61	18605	all
## 62	發現	23872	62	20970	all
## 63	賴	23781	63	16125	all
## 64	立委	23697	64	17483	all
## 65	因	23330	65	21330	all
## 66	已	23243	66	21044	all
## 67	調查	23167	67	19220	all
## 68	都	23092	68	20346	all
## 69	指出	23045	69	22728	all
## 70	4	22781	70	19855	all
## 71	哲	22453	71	14297	all
## 72	自己	22438	72	19022	all
## 73	㊦有	21977	73	19189	all
## 74	和	21507	74	17793	all
## 75	5	21402	75	18870	all
## 76	跟	21213	76	17565	all
## 77	男子	20713	77	15449	all
## 78	我	20494	78	13075	all
## 79	依	20250	79	18416	all
## 80	多	20149	80	17965	all
## 81	這	20140	81	18193	all
## 82	黨	19999	82	13527	all
## 83	萬元	19934	83	14724	all
## 84	遭	19778	84	17403	all
## 85	分	19477	85	16186	all
## 86	小	19266	86	12596	all
## 87	今	19204	87	18762	all
## 88	德	19140	88	14233	all
## 89	該	19098	89	16180	all
## 90	李	18916	90	12213	all


```
## 91      人員      18698  91  14908  all
## 92      向      18625  92  17039  all
## 93      許      18586  93  15277  all
## 94      10      18579  94  16677  all
## 95      長      18579  94  15239  all
## 96      或      18303  96  14481  all
## 97      6       18281  97  15998  all
## 98      政府      18281  97  14640  all
## 99      清      17969  99  13651  all
## 100     相關      17961 100  16032  all
```

```
## Two problems occurred: Digits, and Unknown words wrongly segmented
```

3.1.2 Clean it up a little bit

```
## Example with numbers
table_FreqWord <- Article_tokens_frequency[-grep("[[:digit:]]",
  ↳ Article_tokens_frequency$feature),]

## Redo the ranking
table_FreqWord$rank <- 1:length(table_FreqWord$rank)
```

3.1.3 Final table, addition of the percentage

```
table_FreqWord_Top100 <- head(table_FreqWord, 100)
table_FreqWord_Top100
```

```
##      feature frequency rank docfreq group
## 1      的      357709    1  159298  all
## 2      在      116544    2   88581  all
## 3      日      84106     3   66187  all
## 4      後      71392     4   57501  all
## 5      人      69084     5   49761  all
## 6      時      67573     6   53558  all
## 7      有      65657     7   53298  all
## 8      男      63140     8   32390  all
## 9      與      61733     9   49197  all
## 10     是      59999    10   48402  all
## 11     也      59965    11   51054  all
## 12     及      49873    12   38094  all
## 13     表示      49840    13   47384  all
## 14     年      48807    14   33965  all
## 15     但      47947    15   43097  all
## 16     他      47910    16   34208  all
## 17     將      45675    17   39070  all
## 18     等      44905    18   36914  all
## 19     被      44599    19   36588  all
## 20     到      44505    20   38318  all
## 22     月      43394    21   32669  all
```

## 23	姓	42361	22	28582	all
## 24	對	41664	23	35874	all
## 25	陳	41052	24	26393	all
## 26	民 [F]	40981	25	29991	all
## 27	要	39541	26	31461	all
## 28	[F]	38658	27	34703	all
## 29	台 灣	38028	28	24641	all
## 30	案	36770	29	29132	all
## 32	[F]	35360	30	30056	all
## 33	警 方	35205	31	26808	all
## 34	中	34824	32	30380	all
## 36	[F]	33596	33	29140	all
## 37	柯	33164	34	18553	all
## 38	文	32255	35	21397	all
## 39	以	32162	36	28049	all
## 40	[F]	31311	37	20937	all
## 41	上	31281	38	27774	all
## 42	不	30456	39	26271	all
## 43	民 進 黨	29648	40	20912	all
## 44	就	29633	41	25843	all
## 45	林	29426	42	19296	all
## 46	之	29209	43	18968	all
## 47	女	29041	44	16593	all
## 48	車	28849	45	18869	all
## 49	歲	27927	46	19862	all
## 50	讓	27838	47	24172	all
## 51	名	27598	48	22325	all
## 52	於	27440	49	23486	all
## 53	而	27073	50	25039	all
## 54	她	26964	51	17524	all
## 55	會	26866	52	22316	all
## 56	發 生	26700	53	23129	all
## 57	了	25947	54	21844	all
## 58	前	25547	55	22155	all
## 59	大	25397	56	21497	all
## 60	國 民 黨	25126	57	17804	all
## 61	檢	24367	58	18605	all
## 62	發 現	23872	59	20970	all
## 63	賴	23781	60	16125	all
## 64	立 委	23697	61	17483	all
## 65	因	23330	62	21330	all
## 66	已	23243	63	21044	all
## 67	調 查	23167	64	19220	all
## 68	都	23092	65	20346	all
## 69	指 出	23045	66	22728	all
## 71	哲	22453	67	14297	all
## 72	自 己	22438	68	19022	all
## 73	[F] 有	21977	69	19189	all
## 74	和	21507	70	17793	all
## 76	跟	21213	71	17565	all
## 77	男 子	20713	72	15449	all
## 78	我	20494	73	13075	all
## 79	依	20250	74	18416	all
## 80	多	20149	75	17965	all

## 81	這	20140	76	18193	all
## 82	黨	19999	77	13527	all
## 83	萬元	19934	78	14724	all
## 84	遭	19778	79	17403	all
## 85	分	19477	80	16186	all
## 86	小	19266	81	12596	all
## 87	今	19204	82	18762	all
## 88	德	19140	83	14233	all
## 89	該	19098	84	16180	all
## 90	李	18916	85	12213	all
## 91	人員	18698	86	14908	all
## 92	向	18625	87	17039	all
## 93	許	18586	88	15277	all
## 95	長	18579	89	15239	all
## 96	或	18303	90	14481	all
## 98	政府	18281	91	14640	all
## 99	清	17969	92	13651	all
## 100	相關	17961	93	16032	all
## 101	國	17914	94	13623	all
## 102	處	17898	95	15036	all
## 103	警	17804	96	15484	all
## 104	總統	17774	97	13169	all
## 105	區	17680	98	12860	all
## 107	張	17594	99	11644	all
## 108	進行	17570	100	15739	all

```
table_FreqWord_Top100$percentage <-
  ↪ round(table_FreqWord_Top100$frequency/sum(table_FreqWord$frequency)*100, 5)
table_FreqWord_Top100
```

##	feature	frequency	rank	docfreq	group	percentage
## 1	的	357709	1	159298	all	2.37874
## 2	在	116544	2	88581	all	0.77501
## 3	日	84106	3	66187	all	0.55930
## 4	後	71392	4	57501	all	0.47475
## 5	人	69084	5	49761	all	0.45940
## 6	時	67573	6	53558	all	0.44936
## 7	有	65657	7	53298	all	0.43661
## 8	男	63140	8	32390	all	0.41988
## 9	與	61733	9	49197	all	0.41052
## 10	是	59999	10	48402	all	0.39899
## 11	也	59965	11	51054	all	0.39876
## 12	及	49873	12	38094	all	0.33165
## 13	表示	49840	13	47384	all	0.33143
## 14	年	48807	14	33965	all	0.32456
## 15	但	47947	15	43097	all	0.31884
## 16	他	47910	16	34208	all	0.31860
## 17	將	45675	17	39070	all	0.30374
## 18	等	44905	18	36914	all	0.29862
## 19	被	44599	19	36588	all	0.29658
## 20	到	44505	20	38318	all	0.29596
## 22	月	43394	21	32669	all	0.28857
## 23	姓	42361	22	28582	all	0.28170

## 24	對	41664	23	35874	all	0.27706
## 25	陳	41052	24	26393	all	0.27299
## 26	民 [F]	40981	25	29991	all	0.27252
## 27	要	39541	26	31461	all	0.26295
## 28	[F]	38658	27	34703	all	0.25707
## 29	台灣	38028	28	24641	all	0.25288
## 30	案	36770	29	29132	all	0.24452
## 32	[F]	35360	30	30056	all	0.23514
## 33	警方	35205	31	26808	all	0.23411
## 34	中	34824	32	30380	all	0.23158
## 36	[F]	33596	33	29140	all	0.22341
## 37	柯	33164	34	18553	all	0.22054
## 38	文	32255	35	21397	all	0.21449
## 39	以	32162	36	28049	all	0.21388
## 40	[F]	31311	37	20937	all	0.20822
## 41	上	31281	38	27774	all	0.20802
## 42	不	30456	39	26271	all	0.20253
## 43	民進黨	29648	40	20912	all	0.19716
## 44	就	29633	41	25843	all	0.19706
## 45	林	29426	42	19296	all	0.19568
## 46	之	29209	43	18968	all	0.19424
## 47	女	29041	44	16593	all	0.19312
## 48	車	28849	45	18869	all	0.19184
## 49	歲	27927	46	19862	all	0.18571
## 50	讓	27838	47	24172	all	0.18512
## 51	名	27598	48	22325	all	0.18352
## 52	於	27440	49	23486	all	0.18247
## 53	而	27073	50	25039	all	0.18003
## 54	她	26964	51	17524	all	0.17931
## 55	會	26866	52	22316	all	0.17866
## 56	發生	26700	53	23129	all	0.17755
## 57	了	25947	54	21844	all	0.17255
## 58	前	25547	55	22155	all	0.16989
## 59	大	25397	56	21497	all	0.16889
## 60	國民黨	25126	57	17804	all	0.16709
## 61	檢	24367	58	18605	all	0.16204
## 62	發現	23872	59	20970	all	0.15875
## 63	賴	23781	60	16125	all	0.15814
## 64	立委	23697	61	17483	all	0.15758
## 65	因	23330	62	21330	all	0.15514
## 66	已	23243	63	21044	all	0.15456
## 67	調查	23167	64	19220	all	0.15406
## 68	都	23092	65	20346	all	0.15356
## 69	指出	23045	66	22728	all	0.15325
## 71	哲	22453	67	14297	all	0.14931
## 72	自己	22438	68	19022	all	0.14921
## 73	[F]有	21977	69	19189	all	0.14615
## 74	和	21507	70	17793	all	0.14302
## 76	跟	21213	71	17565	all	0.14107
## 77	男子	20713	72	15449	all	0.13774
## 78	我	20494	73	13075	all	0.13628
## 79	依	20250	74	18416	all	0.13466
## 80	多	20149	75	17965	all	0.13399
## 81	這	20140	76	18193	all	0.13393

## 82	黨	19999	77	13527	all	0.13299
## 83	萬元	19934	78	14724	all	0.13256
## 84	遭	19778	79	17403	all	0.13152
## 85	分	19477	80	16186	all	0.12952
## 86	小	19266	81	12596	all	0.12812
## 87	今	19204	82	18762	all	0.12771
## 88	德	19140	83	14233	all	0.12728
## 89	該	19098	84	16180	all	0.12700
## 90	李	18916	85	12213	all	0.12579
## 91	人員	18698	86	14908	all	0.12434
## 92	向	18625	87	17039	all	0.12386
## 93	許	18586	88	15277	all	0.12360
## 95	長	18579	89	15239	all	0.12355
## 96	或	18303	90	14481	all	0.12171
## 98	政府	18281	91	14640	all	0.12157
## 99	清	17969	92	13651	all	0.11949
## 100	相關	17961	93	16032	all	0.11944
## 101	國	17914	94	13623	all	0.11913
## 102	處	17898	95	15036	all	0.11902
## 103	警	17804	96	15484	all	0.11840
## 104	總統	17774	97	13169	all	0.11820
## 105	ㄈ	17680	98	12860	all	0.11757
## 107	張	17594	99	11644	all	0.11700
## 108	進行	17570	100	15739	all	0.11684

3.2 Save the data

3.2.1 Save as an Excel file

```
write.xlsx(table_FreqWord_Top100, "ArticleETToday_Top100words.xlsx")
```

3.2.2 Save as an RData file

```
save(table_FreqWord_Top100, file = "ArticleETToday_Top100words.Rdata")
```